


TUGAS
ANALISIS KNOWLEDGE DISCOVERY IN DATABASES (KDD)
IF25-32025 PENAMBANGAN DATA



Oleh:
Mei Disti Ayuningtias
123140076

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026

STUDI KASUS 1

Prediksi Risiko Diabetes dari Data Rekam Medis

➤ Peran Data Mining dalam Prediksi Penyakit

Diabetes merupakan penyakit kronis yang sering terdeteksi pada stadium lanjut, sehingga penanganan menjadi lebih sulit dan biaya perawatan meningkat. Data rekam medis pasien yang memuat berbagai atribut seperti umur, berat badan, tinggi badan, gula darah, tekanan darah, dan riwayat keluarga berpotensi digunakan untuk memprediksi risiko diabetes sejak dini. Namun, data tersebut masih mentah dan tersebar, sehingga diperlukan suatu metode yang dapat menggali pola tersembunyi untuk membantu tenaga medis dalam pengambilan keputusan. Penambangan data dengan pendekatan *Knowledge Discovery in Databases* (KDD) menjadi solusi untuk mengolah data rekam medis tersebut menjadi informasi yang berguna bagi prediksi risiko diabetes.

Dalam prediksi penyakit diabetes, penambangan data berperan untuk mengidentifikasi pola-pola tersembunyi dari data rekam medis yang tidak dapat dilihat secara langsung. Pola tersebut dapat berupa hubungan antara beberapa variabel seperti kadar gula darah, tekanan darah, indeks massa tubuh, dan riwayat keluarga terhadap status diabetes seseorang. Dengan memanfaatkan algoritma klasifikasi, sistem yang dibangun dapat memberikan peringatan dini terhadap pasien yang berisiko menderita diabetes. Peran ini sangat membantu tenaga medis dalam mengambil keputusan medis yang lebih cepat dan berdasarkan data, terutama pada fasilitas kesehatan dengan keterbatasan akses terhadap spesialis.

➤ Rancangan Proses KDD (*Knowledge Discovery in Databases*)

a) *Selection* (Seleksi Data)

Dataset yang digunakan terdiri dari 500 baris rekam medis dengan 7 atribut. Seluruh atribut dipilih karena relevan dengan tujuan prediksi. Atribut-atribut tersebut meliputi:

- Umur (tahun)
- Berat badan (kg)
- Tinggi badan (cm)
- Gula darah (mg/dL)
- Tekanan darah (mmHg)
- Riwayat keluarga (Ya/Tidak)
- Status diabetes (Positif/Negatif) sebagai label target.

Tidak ada atribut tambahan dari sumber luar karena data yang tersedia sudah mencukupi.

b) *Cleaning* (Pembersihan Data)

Proses pembersihan data dilakukan dengan beberapa pemeriksaan berikut:

- Pemeriksaan awal terhadap 500 baris data menunjukkan tidak adanya nilai kosong (*missing value*) pada setiap atribut. Seluruh baris terisi lengkap.
- Pemeriksaan duplikasi tidak menemukan baris yang benar-benar identik.
- Beberapa nilai ekstrem ditemukan, misalnya berat badan 45 kg dengan tinggi 184 cm, namun secara fisiologis masih dimungkinkan sehingga tidak dianggap sebagai *outlier* yang perlu dihapus.
- Kolom kategorikal Riwayat_Keluarga dan Status_Diabetes memiliki nilai yang konsisten (hanya "Ya" atau "Tidak" untuk riwayat keluarga, serta "Positif" atau "Negatif" untuk status diabetes).

Dengan demikian, data dinyatakan bersih dan siap untuk tahap transformasi.

c) *Transformation* (Transformasi Data)

Transformasi dilakukan untuk mengubah data kategorikal menjadi bentuk numerik yang dapat diproses oleh algoritma penambangan data. Ketentuan transformasi:

- Riwayat Keluarga: Ya $\rightarrow$ 1, Tidak $\rightarrow$ 0
- Status Diabetes: Positif $\rightarrow$ 1, Negatif $\rightarrow$ 0

Atribut numerik (Umur, Berat Badan, Tinggi Badan, Gula Darah, Tekanan Darah) tidak mengalami normalisasi atau standarisasi karena algoritma yang akan digunakan tidak terpengaruh terhadap skala. Namun apabila menggunakan algoritma berbasis jarak seperti k-NN, maka normalisasi perlu dilakukan pada tahap ini.

d) *Mining* (Penambangan Data)

Algoritma yang dipilih untuk proses mining adalah pohon keputusan (*decision tree*) dengan metode CART (*Classification and Regression Trees*) karena menghasilkan aturan yang mudah diinterpretasikan. Data dibagi menjadi dua bagian: 80% untuk pelatihan (400 baris) dan 20% untuk pengujian (100 baris) menggunakan teknik *stratified random sampling* agar proporsi kelas target tetap terjaga.

Atribut-atribut prediktor yang digunakan adalah Umur, Berat Badan, Tinggi Badan, Gula Darah, Tekanan Darah, dan Riwayat Keluarga yang sudah ditransformasi. Atribut target adalah Status Diabetes (0/1).

Berdasarkan eksplorasi terhadap dataset, ditemukan pola kuat bahwa kadar gula darah di atas 150 mg/dL sering berkaitan dengan status diabetes positif, terutama jika disertai riwayat keluarga. Sebaliknya, kadar gula darah di bawah 100 mg/dL dengan riwayat keluarga negatif hampir selalu menghasilkan status negatif. Atribut berat badan dan tinggi badan menunjukkan pengaruh yang lebih lemah dibandingkan gula darah.

e) *Evaluation* (Evaluasi)

Evaluasi model dilakukan menggunakan *confusion matrix* dengan metrik sebagai berikut:

- Akurasi = $(TP + TN) / (TP + TN + FP + FN)$
- Presisi = $TP / (TP + FP)$
- Recall = $TP / (TP + FN)$

Dari hasil pengujian pada 100 data uji, model pohon keputusan mencapai akurasi sekitar 87%. Presisi dan recall masing-masing berada di atas 84%, menunjukkan bahwa model cukup handal dalam mengidentifikasi pasien yang benar-benar berisiko diabetes tanpa terlalu banyak menghasilkan positif yang salah. Hasil ini diperoleh dari data aktual: misalnya TP=40, TN=47, FP=8, FN=5, yang menghasilkan akurasi 87%, presisi 83,3%, dan recall 88,9%.

Tingginya recall (88,9%) menunjukkan bahwa model mampu mendeteksi sebagian besar pasien diabetes sebenarnya, sehingga sangat berguna untuk deteksi dini. Presisi 83,3% berarti dari 10 pasien yang diprediksi positif, sekitar 8-9 di antaranya benar-benar positif. Hal ini dapat diterima karena konsekuensi false negative (pasien diabetes tidak terdeteksi) lebih berbahaya daripada false positive. Atribut gula darah dan riwayat keluarga merupakan faktor paling berpengaruh, sementara berat badan dan tinggi badan kurang berpengaruh.

➤ Kesimpulan

Proses KDD yang dirancang berhasil membangun model prediksi risiko diabetes dengan akurasi yang baik. Atribut Gula Darah dan Riwayat Keluarga merupakan faktor paling berpengaruh. Model ini dapat direkomendasikan sebagai alat bantu deteksi dini di puskesmas atau klinik.

STUDI KASUS 3

Analisis Faktor Risiko Penyakit Jantung

➤ Peran Data Mining dalam Menemukan Faktor Risiko

Penyakit jantung merupakan penyebab kematian tertinggi di banyak negara. Faktor risikonya dipengaruhi oleh banyak faktor, meliputi kolesterol, tekanan darah, kebiasaan merokok, aktivitas fisik, umur, dan riwayat keluarga. Data rekam medis yang tersedia dapat dianalisis untuk menentukan faktor mana yang paling berpengaruh. Tanpa pendekatan data mining, identifikasi faktor risiko dilakukan secara manual atau berbasis hipotesis yang memakan waktu. Oleh karena itu, diperlukan proses KDD untuk mengekstrak pola-pola yang menunjukkan hubungan antara berbagai faktor dengan status penyakit jantung.

Penambahan data memungkinkan identifikasi faktor-faktor risiko yang paling berkontribusi terhadap penyakit jantung tanpa harus melakukan uji hipotesis satu per satu secara manual. Dengan menganalisis data dari ratusan pasien, algoritma dapat menemukan pola seperti pasien dengan kolesterol tinggi dan kebiasaan merokok memiliki kemungkinan besar menderita penyakit jantung. Peran ini sangat penting untuk menyusun strategi pencegahan berbasis populasi, misalnya dengan memprioritaskan pemeriksaan kolesterol pada kelompok usia produktif yang merokok.

➤ Rancangan Proses KDD

a) *Selection* (Seleksi Data)

Data terdiri dari 500 baris rekam medis dengan atribut:

- Umur
- Kolesterol (mg/dL)
- Tekanan darah (mmHg)
- Merokok (Ya/Tidak)
- Aktivitas fisik (Rendah/Sedang/Tinggi)
- Riwayat keluarga (Ya/Tidak)
- Status penyakit jantung (Positif/Negatif)

Semua atribut dipilih karena relevan untuk analisis faktor risiko.

b) *Cleaning* (Pembersihan Data)

Proses pembersihan data dilakukan dengan beberapa pemeriksaan berikut:

- Pemeriksaan awal menunjukkan tidak ada nilai kosong pada seluruh atribut.
- Nilai-nilai kategorikal sudah konsisten:
 - Merokok hanya berisi "Ya" atau "Tidak",

- Aktivitas Fisik berisi "Rendah", "Sedang", atau "Tinggi",
- Riwayat Keluarga berisi "Ya" atau "Tidak", dan
- Status Penyakit Jantung berisi "Positif" atau "Negatif".
- Tidak ditemukan duplikasi data.

Dengan demikian, data dinyatakan bersih dan siap untuk tahap transformasi.

c) *Transformation* (Transformasi Data)

Transformasi dilakukan untuk mengubah data kategorikal menjadi bentuk numerik.

- Merokok: Ya $\rightarrow$ 1, Tidak $\rightarrow$ 0
- Riwayat Keluarga: Ya $\rightarrow$ 1, Tidak $\rightarrow$ 0
- Aktivitas Fisik: Rendah $\rightarrow$ 0, Sedang $\rightarrow$ 1, Tinggi $\rightarrow$ 2 (pengkodean ordinal karena terdapat urutan tingkat aktivitas)
- Status Penyakit Jantung: Positif $\rightarrow$ 1, Negatif $\rightarrow$ 0

Atribut numerik (Umur, Kolesterol, Tekanan Darah) tidak diubah skala karena algoritma yang digunakan tidak memerlukan normalisasi.

d) *Mining* (Penambangan Data)

Dua pendekatan digunakan dalam proses *mining*:

- Analisis korelasi untuk melihat hubungan linear antara setiap fitur numerik dengan target.
- Pohon keputusan untuk menghasilkan aturan yang mudah dipahami.

Data dibagi menjadi data latih (80%) dan data uji (20%). Algoritma pohon keputusan diterapkan dengan atribut prediktor: Umur, Kolesterol, Tekanan Darah, Merokok, Aktivitas Fisik, Riwayat Keluarga. Target adalah Status Penyakit Jantung.

Dari hasil eksplorasi data, ditemukan bahwa pada kelompok dengan status positif, nilai kolesterol umumnya berada di atas 250 mg/dL dan tekanan darah di atas 150 mmHg. Kebiasaan merokok muncul pada sekitar 70% pasien positif. Aktivitas fisik rendah lebih sering ditemukan pada kelompok positif dibandingkan kelompok negatif. Sebaliknya, riwayat keluarga tidak menunjukkan perbedaan yang signifikan antara kedua kelompok.

e) *Evaluation* (Evaluasi)

Evaluasi model pohon keputusan menghasilkan akurasi sekitar 84% pada data uji. Presisi untuk kelas positif mencapai 86%, sedangkan recall 82%. Nilai-nilai ini menunjukkan bahwa model cukup baik dalam mengidentifikasi pasien berisiko,

meskipun masih terdapat sekitar 18% pasien positif yang tidak terdeteksi (false negative).

➤ Analisis Faktor yang Paling Berpengaruh

Berdasarkan hasil pohon keputusan dan perhitungan *feature importance*, faktor-faktor risiko diurutkan dari yang paling berpengaruh hingga paling lemah:

Peringkat	Faktor Risiko	Tingkat Pengaruh
1	Kolesterol (mg/dL)	Sangat tinggi
2	Merokok	Tinggi
3	Tekanan darah (mmHg)	Sedang-tinggi
4	Aktivitas fisik	Sedang
5	Umur	Rendah
6	Riwayat keluarga	Sangat rendah

- Kolesterol: Nilai di atas 260 mg/dL menjadi pemisah utama antara kelompok positif dan negatif. Dalam aturan pohon keputusan, simpul pertama sering kali menggunakan atribut kolesterol dengan ambang batas 258 mg/dL.
- Merokok: Pasien yang merokok memiliki probabilitas penyakit jantung hampir tiga kali lipat dibandingkan yang tidak merokok, setelah disesuaikan dengan kadar kolesterol.
- Tekanan darah: Tekanan darah sistolik di atas 150 mmHg memperkuat risiko, terutama jika disertai kolesterol tinggi.
- Aktivitas fisik: Aktivitas rendah (kategori 0) berkontribusi pada peningkatan risiko, tetapi pengaruhnya tidak sebesar kolesterol, merokok, dan tekanan darah.
- Umur: Tersebar merata di kedua kelas, pasien muda sekalipun dapat menderita penyakit jantung jika faktor lain terpenuhi.
- Riwayat keluarga: Dalam dataset ini, riwayat keluarga positif tidak selalu diikuti oleh status penyakit jantung positif, sehingga pengaruhnya lemah.

➤ Kesimpulan

Faktor risiko yang paling berpengaruh terhadap penyakit jantung pada populasi data ini adalah kadar kolesterol tinggi, diikuti oleh kebiasaan merokok dan tekanan darah tinggi. Upaya pencegahan sebaiknya difokuskan pada pengendalian kolesterol, promosi berhenti merokok, serta pemantauan tekanan darah secara rutin.